



# Prediksi Kurs Rupiah Terhadap Dolar dengan Menggunakan Model *Long-Short Term Memory*

Adella Devi<sup>a\*</sup>, Putriaji Hendikawati<sup>b</sup>

<sup>a</sup> Jurusan Matematika, FMIPA, Universitas Negeri Semarang, Indonesia

<sup>b</sup> Gedung D7 Lt.1, Kampus Sekaran Gunung Pati, Semarang 50229

\* Alamat Surel: [adellaneta312@gmail.com](mailto:adellaneta312@gmail.com)

## Abstrak

Kebijakan moneter, investasi, dan perdagangan Internasional sangat dipengaruhi oleh perubahan kurs antara Dolar dan Rupiah. Nilai tukar mata uang atau kurs merupakan komponen penting dalam kestabilan ekonomi suatu negara. Prediksi atau peramalan dapat dilakukan sebagai tindakan preventif untuk mencegah terjadinya depresiasi. Penelitian ini dilakukan untuk melihat keakurasian proses peramalan data runtun waktu nilai tukar mata uang Rupiah-Dolar menggunakan pemodelan Long-Short Term Memory. Tujuan dari penelitian ini adalah untuk melihat arsitektur yang akurat pada pemodelan LSTM. Data yang digunakan adalah data Kurs Rupiah-Dolar yang diperoleh melalui laman Jakarta Interbank Spot Dollar Rate (JISDOR) Bank Indonesia periode 5 April 2018 sampai 26 Mei 2023. Metode yang digunakan merupakan pengembangan dari neural network yaitu Long-Short Term Memory menggunakan bahasa pemrograman python. Hasilnya arsitektur pemodelan dengan 320 neuron pada lapisan pertama, 416 neuron pada lapisan kedua, 224 neuron pada lapisan ketiga, 128 neuron pada lapisan keempat, dan 1 lapisan dense, serta fungsi aktivasi ReLu menghasilkan nilai MSE dan RMSE dengan nilai terkecil sebesar 0,000444 dan 0,0210. Percobaan prediksi dengan metode ARIMA juga dilakukan guna memperkuat hasil analisis yang dilakukan. Kesimpulannya, model LSTM lebih unggul daripada model ARIMA. RMSE yang dihasilkan model LSTM adalah 0,0182 sedangkan ARIMA sebesar 0,1823.

Kata kunci: Kurs, prediksi, lstm, arima

© 2024 Dipublikasikan oleh Jurusan Matematika, Universitas Negeri Semarang

## 1. Pendahuluan

Statistika merupakan rumpun ilmu yang sangat relevan digunakan di berbagai bidang kehidupan dan keilmuan. Di era digital ini, jumlah data yang dihasilkan semakin melimpah. Organisasi, pemerintahan, dan perusahaan berusaha untuk memanfaatkan data untuk mengambil keputusan yang lebih baik dan berorientasi data. Perkembangan *big data* atau jumlah data yang sangat besar, kompleks, dan heterogen tidak dapat diolah dengan metode konvensional. Oleh karena itu, ilmu statistika menjadi kunci untuk menganalisis, mengelola, dan memahami big data agar dapat memberikan wawasan berharga bagi organisasi dan bisnis. Salah satu pemanfaatan ilmu statistika yaitu proses prediksi atau peramalan. Prediksi atau peramalan (*forecast*) adalah proses membuat perkiraan tentang kejadian atau kondisi di masa depan berdasarkan informasi dan data yang tersedia pada saat ini. Tujuan dari prediksi adalah untuk mengidentifikasi pola atau tren dari data historis yang dapat digunakan untuk memperkirakan apa yang mungkin terjadi di masa depan (Rob J Hyndman & George, 2014). Ada berbagai macam metode yang digunakan untuk memprediksi suatu data, mulai dari metode konvensional seperti Moving Average, Exponential Smoothing, Metode Dekomposisi dan sebagainya. Pada bidang *machine learning* metode prediksi yang umum digunakan adalah Random Forest, Support Vector Machine, Jaringan Saraf Tiruan atau Neural Network dan lainnya.

Nilai tukar mata uang atau kurs merupakan komponen penting dalam kestabilan ekonomi suatu negara. Kebijakan moneter, investasi, dan perdagangan Internasional sangat dipengaruhi oleh perubahan kurs antara Dolar dan Rupiah. Maka dari itu, Lembaga Negara Bank Indonesia memiliki peran yang sangat penting dalam menjaga kestabilan Kurs Rupiah terhadap mata uang asing karena dampak negatif dari pelemahan nilai Rupiah akan dirasakan dalam skala yang lebih besar oleh perekonomian Indonesia (Johan, 2020). Penelitian yang dilakukan oleh Pamungkas et al. (2020) berjudul “Analisis Pengaruh

To cite this article:

Devi, A & Hendikawati, P. (2024). Prediksi Kurs Rupiah Terhadap Dolar dengan Menggunakan Model *Long-Short Term Memory*. *PRISMA, Prosiding Seminar Nasional Matematika* 7, 882-891.

Ekspor, Impor, Inflasi, Kurs Rupiah, dan Utang Luar Negeri terhadap Cadangan Devisa Indonesia Tahun 1999 – 2018” menunjukkan hasil bahwa Kurs Rupiah memiliki pengaruh positif dan signifikan terhadap cadangan devisa di Negara Indonesia. Arus modal antar negara sangat memengaruhi nilai mata uang setiap negara. Di bidang investasi, Kurs Rupiah juga dapat menjadi salah satu faktor yang mampu mempengaruhi indeks harga saham (Rismala & Elwisam, 2020). Sebagai langkah antisipasi maka perlu dilakukan prediksi terhadap kurs Rupiah terhadap mata uang asing.

Prediksi nilai tukar Rupiah sangat diperlukan untuk menghindari masalah-masalah perekonomian yang dapat berdampak pada keberlangsungan hidup di negara Indonesia. Memahami dan memprediksi perubahan kurs dengan tepat dapat membantu individu, pelaku bisnis, dan pemerintah membuat keputusan yang lebih baik mengenai ekspor dan impor, alokasi dana, dan manajemen risiko mata uang. Sehingga, dapat diambil langkah konkrit setelah proses penelitian dengan menggunakan metode prediksi atau peramalan selesai, tentunya dengan melihat berbagai faktor yang dapat memengaruhi peningkatan atau penurunan nilai tukar Rupiah selain nilai kurs itu sendiri.

Saat ini proses prediksi atau peramalan bisa dilakukan dengan sangat mudah dan efisien karena adanya metode *machine learning* atau pembelajaran mesin. Dari pasar saham hingga nilai tukar mata uang, dari pendeteksi suhu ruang hingga klasifikasi jenis penyakit, dan dari *speech recognition* hingga *image classification*. Saat dikumpulkan bersama, pengukuran membentuk apa yang dikenal sebagai *time series*. Pada penelitian ini akan dibahas mengenai prediksi Kurs Rupiah-Dolar berbentuk data *time series*. Ada berbagai macam metode yang digunakan untuk memprediksi suatu data *time series*, mulai dari metode konvensional seperti Moving Average, Exponential Smoothing, Metode Dekomposisi dan sebagainya. Pada bidang *machine learning* metode prediksi yang umum digunakan adalah Random Forest, Support Vector Machine, jaringan saraf tiruan atau Neural Network dan lainnya. Namun, pada metode jaringan saraf tiruan, *vanishing gradient* (gradien yang menghilang) adalah salah satu tantangan utama yang terjadi saat melatih jaringan. Pemodelan Long-Short Term Memory dimunculkan untuk mengatasi gradien yang perlahan menghilang pada Recurrent Neural Network. LSTM dapat diterapkan pada berbagai tugas logis dan bahasa pemodelan, serta mengatasi dependensi dalam waktu yang lama pada masukannya (Sanjaya & Heksaputra, 2020). Menurut (Abedin et al., 2021) penggunaan model LSTM dalam memprediksi nilai tukar mata uang di beberapa negara selama pandemi Covid-19 menghasilkan performa yang baik. Penelitian Nagpure (2019), prediksi nilai tukar multi mata uang dalam jumlah banyak menggunakan deep learning juga menunjukkan hasil yang maksimal. Penelitian dengan menggunakan pengembangan dari metode LSTM yaitu Bi-LSTM pada optimalisasi penggunaan air dan hasil panen, memperkirakan kelembaban tanah di masa depan juga menghasilkan nilai eror yang kecil (Suebsombut et al., 2021). Penelitian serupa dilakukan oleh (Oxaichiko Arissinta et al., 2022) yang bertujuan untuk melihat perbandingan prediksi *web traffic* pada Juli 2015 sampai Desember 2016 menggunakan metode ARIMA, LSTM, dan GRU. Hasil yang didapatkan dari penelitian ini adalah metode LSTM dan GRU memiliki nilai eror MSE yang tidak jauh berbeda sedangkan metode ARIMA memperoleh nilai eror yang cukup besar. Penelitian lain oleh Rachman (2018) mengenai peramalan produksi industri garment dalam jangka pendek menggunakan metode Moving Average dan Exponential Smoothing. Hasil yang didapatkan dari penelitian ini menunjukkan metode Exponential Smoothing  $\alpha = 0,5$  mendapatkan nilai MSE yang lebih rendah daripada Moving Average.

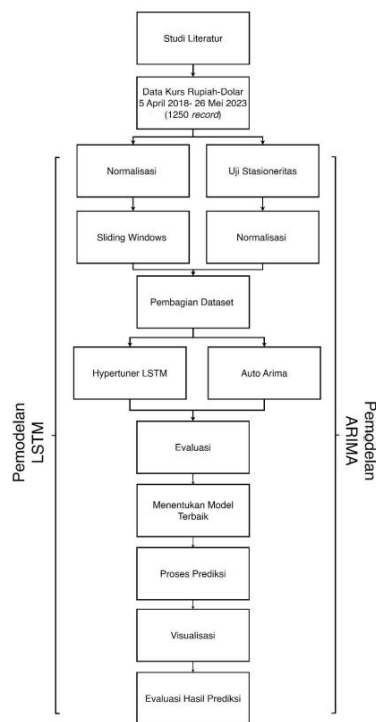
Kelebihan dari metode ARIMA adalah kemampuannya untuk diterapkan pada berbagai pola data runtun waktu. Metode ini menggunakan data masa lalu dan saat ini dari variabel dependen untuk membuat peramalan jangka pendek yang akurat. Metode ARIMA khususnya digunakan untuk prediksi harga dalam pengolahan data yang kecil dan untuk jangka waktu yang pendek. Namun, untuk prediksi dalam skala besar dan jangka waktu yang lebih panjang, metode ARIMA konvensional kurang efektif. Oleh karena itu, hasil dari Metode ARIMA menurut penulis tidak dapat memenuhi kebutuhan pengambilan keputusan yang mendesak. Dari ulasan dan pembahasan tersebut, penulis tertarik menggunakan pendekatan LSTM dalam memprediksi nilai tukar Rupiah terhadap Dolar selama lima tahun pada periode 5 April 2018–26 Mei 2023 karena dianggap mampu untuk digunakan terhadap data yang berbentuk data runtun waktu dalam jumlah yang relatif banyak dan mampu mengatasi ketergantungan jangka panjang (*long term dependencies*) pada masukannya. LSTM juga memiliki fleksibilitas untuk digunakan dalam berbagai tugas berurutan dan pemodelan bahasa. Dalam LSTM, sel memori memungkinkan penyimpanan nilai atau keadaan (*state*) yang memungkinkan prediksi baik dalam jangka waktu yang panjang maupun pendek. Keunggulan ini membuat LSTM menjadi pilihan yang kuat

sebagai dasar dalam pengambilan keputusan. Untuk melihat apakah pendekatan LSTM terbukti lebih baik untuk memprediksi nilai tukar Rupiah terhadap Dolar selama lima tahun pada periode 5 April 2018–26 Mei 2023, maka akan ditambahkan analisis menggunakan metode ARIMA sebagai perbandingan.

Dalam memprediksi data runtun waktu diperlukan model yang tepat agar hasil yang diperoleh akurat. Menurut Abedin (2021) berjudul “Deep Learning-Based Exchange Rate Prediction During The Covid-19 Pandemic” penggunaan model LSTM untuk memprediksi data nilai runtun waktu seperti nilai tukar mata uang pada beberapa negara selama pre-Covid-19 dan saat Covid-19 sangat relevan untuk digunakan karena hasil evaluasi model berdasarkan metrik evaluasi RMSE yang ditentukan mencapai capaian yang baik sebesar 0,0219.

Penelitian Susilowati & Rosento (2020) yang berjudul “Peramalan Nilai Tukar Kurs IDR terhadap Dolar USD dengan Metode Moving Average dan Exponential Smoothing”. Penelitian tersebut bertujuan untuk membandingkan tingkat keakuratan antara dua metode yang digunakan. Hasil penelitian menjelaskan bahwa metode peramalan yang paling tepat digunakan dalam menganalisis data adalah metode Exponential Smoothing  $\alpha = 0,9$  dengan hasil peramalan pada periode 14 Februari sebesar Rp13.677,29 dengan MAD sebesar 5,8 dan MSE sebesar 1,376.62. Hasil penelitian tersebut menunjukkan bahwa peramalan dengan metode konvensional Exponential Smoothing masih sangat relevan jika data yang digunakan tidak cukup banyak, berkisar antara hitungan bulan.

## 2. Metode (untuk artikel hasil kajian, bagian ini tidak ada)



**Gambar 2.1.** Diagram Alir Proses Pemodelan LSTM dan ARIMA

Penelitian ini dilakukan dengan tahapan seperti yang terdapat pada Gambar 3.1, dengan penjelasan sebagai berikut.

### 2.1. Studi Literatur

Pada tahap ini, penulis akan mengumpulkan berbagai macam sumber literatur untuk dijadikan referensi. Studi literatur bertujuan untuk memperoleh pemahaman yang komprehensif tentang penelitian atau topik yang telah dilakukan sebelumnya menggunakan metode atau variabel yang sesuai dengan hal yang akan dianalisis. Studi literatur juga membantu penulis memahami perkembangan, tren, dan sudut pandang yang berbeda.

---

## 2.2. Tahap Pengumpulan Data

Pada tahap ini, penulis menentukan data apa yang ingin dianalisis sesuai dengan urgensi yang ada. Penulis memilih data nilai tukar mata uang Rupiah-Dolar yang diambil secara langsung melalui website resmi yang dikelola oleh Bank Indonesia. Penentuan jumlah record pada data sesuai dengan literatur review yang penulis dapatkan. Data yang penulis akan analisis merupakan data univariate atau data yang memiliki satu variabel.

## 2.3. Tahap Pre-Processing Data

Tahap pre-processing data adalah langkah awal sebelum data dilakukan analisis pada tahap selanjutnya. Tahap ini dilakukan untuk mengubah data mentah ke dalam bentuk yang lebih mudah dipahami agar memiliki format yang teratur. Dalam hal ini, penulis melakukan perubahan urutan data dari tanggal terlama hingga terdekat. Kemudian, data juga dilakukan proses normalisasi atau scalling dari skala nilai (0-1) tujuannya adalah untuk mengurangi loss, serta reshape data.

## 2.4. Tahap Pembagian Data

Tahap pembagian data, yaitu membagi data menjadi dua bagian, ada data *training* dan *testing*. Training set digunakan untuk melatih model, sementara testing set digunakan untuk menguji sejauh mana model yang dilatih mampu melakukan prediksi yang akurat pada data yang belum pernah dilihat sebelumnya. Penulis membagi data training menjadi 80% dan 20% sesuai dengan kaidah pembagian data. Data training yang digunakan sebesar 1000 record dan data testing yang digunakan sejumlah 250 *record*. Seribu data training tersebut akan 37 dilatih agar nilai pembobotan dapat di set sesuai dengan yang diinginkan. Proses training tersebut menggunakan optimisasi adam.

## 2.5. Menentukan Model

Dalam hal ini akan dilakukan modelling dengan menggunakan Long-Short Term Memory dengan melibatkan beberapa langkah, seperti mengatur arsitektur model, mengkompilasi model, dan menentukan fungsi loss dan optimizer yang akan digunakan selama proses pelatihan.

## 2.6. Evaluasi

Tahapan evaluasi dilakukan pada saat pelatihan dan proses pengujian. Evaluasi data uji digunakan untuk mengukur performa model tersebut dengan menggunakan data yang belum pernah dilihat sebelumnya (data validasi atau data pengujian). Tujuan dari tahap evaluasi adalah untuk memahami sejauh mana model mampu menggeneralisasi dan membuat prediksi yang akurat pada data yang belum dikenalnya. Metriks Evaluasi yang digunakan pada penelitian ini adalah MSE dan RMSE.


## 2.7. Proses Prediksi

Setelah mendapatkan mengevaluasi kinerja dan mendapatkan model terbaik dari hasil pelatihan data, maka dilakukan proses prediksi. Jika model tidak memberikan hasil yang memuaskan pada data uji, perlu dilakukan pelatihan dan tuning kembali untuk meningkatkan kinerjanya. Jika model memberikan hasil yang cukup optimal maka hasil prediksi dapat digunakan.

---

# 3. Hasil dan Pembahasan

Menurut grafik, nilai tukar mata uang selama lima tahun terakhir mengalami fluktuasi. Dari grafik pada gambar 3.1 juga ditunjukkan bahwa nilai tukar Rupiah-Dolar tidak mengalami seasonalitas. Artinya, tidak terdapat pola perubahan periodik yang terjadi secara teratur selama periode waktu yang singkat atau dengan kata lain nilai tukar mata uang Rupiah-Dolar tidak mengalami perubahan musiman.



**Gambar 2.2.** Grafik Nilai Tukar Mata Uang Rupiah-Dolar Lima Tahun Terakhir

Menggunakan model LSTM, Setelah melihat grafik pada gambar 3.1 maka dilakukan normalisasi data. Pada tahap normalisasi data, penulis menggunakan fungsi `MinMaxScaler()` yang dapat mengubah data numerik ke dalam rentang yang spesifik (0-1). Proses normalisasi ini membantu mengatasi perbedaan skala antara fitur-fitur yang ada dalam dataset. Cara kerja Min-MaxScaler adalah dengan mengurangi nilai terkecil dalam setiap data dan kemudian membagi seluruh data dengan rentang (selisih antara nilai terbesar dan nilai terkecil) dari data tersebut. Hal ini dilakukan untuk setiap data dalam dataset, sehingga seluruh dataset akan memiliki rentang nilai yang seragam dari 0 hingga 1.

Proses pembagian data merupakan bagian dari *supervised learning*. Pembagian data menjadi dua bagian utama, yaitu data latih dan data uji, adalah langkah penting dalam proses pembelajaran mesin (*machine learning*) dan pengujian model. Tujuannya adalah untuk melatih model dengan data latih dan kemudian menguji kinerjanya dengan menggunakan data uji yang belum pernah dilihat sebelumnya. Hal ini dilakukan untuk mengukur sejauh mana model mampu melakukan generalisasi pada data yang tidak dikenal. Dalam hal ini, penulis menggunakan persentase 80% untuk data latih dan 20% untuk data uji.

Pada penyetelan (*tuning*) hyperparameter, penulis menggunakan *library* dari Keras untuk menentukan model yang terbaik dari beberapa kali percobaan secara otomatis. Keras adalah platform high-level deep learning Python yang dapat beroperasi di atas TensorFlow. Dengan menggunakan library Keras, analisis dapat dilakukan secara cepat, efisien, dan akurat. Penyetelan Hyperparameter dilakukan untuk mencari model terbaik yang akan digunakan untuk analisis data uji. Hyperparameter optimization dari Keras yang digunakan untuk melakukan tuning adalah Keras Tuner RandomSearch dengan maksimal percobaan 4 kali. Epoch yang digunakan pada analisis sebesar 20, dengan batch size 128. Hasil penyetelan hyperparameter adalah pada tabel 1.

**Tabel 2.1.** Hasil Penyetelan *Hyperparameter*

Percobaan	MSE	RMSE
Percobaan 1	0,000973	0,0312
Percobaan 2	0,000555	0,0235
<b>Percobaan 3</b>	<b>0,000444</b>	<b>0,0210</b>
Percobaan 4	0,000521	0,0228

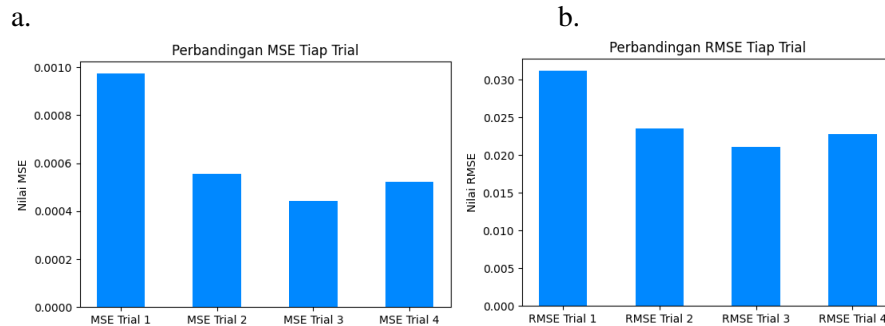
Setelah model dilatih dengan konfigurasi hyperparameter dengan menyimpan MSE dan RMSE terkecil menggunakan `best_model` pada tabel 2.2, diperoleh nilai MSE akhir sebesar 0.000521. Semakin kecil nilai MSE, semakin baik performa model pada tugas yang diberikan. Gambar 2 dan 3 menunjukkan perbandingan metrik evaluasi MSE dan RMSE dari tiap-tiap percobaan yang dilakukan.

**Tabel 2.2.** *Syntax* Pemanggilan Best Model

```

best_model = tuner.get_best_models(num_models=1)[0]
best_model.save('Model 1.h5')
# Memuat model yang telah disimpan
best_model = load_model('Model 1.h5')
# Tampilan ringkasan model
best_model.summary()

```

**Gambar 2.3.** (a) Perbandingan MSE setiap percobaan;(b) Perbandingan RMSE setiap percobaan

Setelah menentukan model terbaik pada proses analisis data, selanjutnya adalah melakukan proses prediksi terhadap data uji dengan menggunakan *syntax* seperti pada tabel 4.9. Dengan cara ini, dapat dibandingkan hasil prediksi ( $y_{pred}$ ) dengan nilai target asli ( $y_{tests}$ ) untuk mengevaluasi seberapa baik model yang telah dihasilkan dari proses penyetelan *hyperparameter* tersebut.

**Tabel 2.3.** Sintaks Proses Peramalan

```

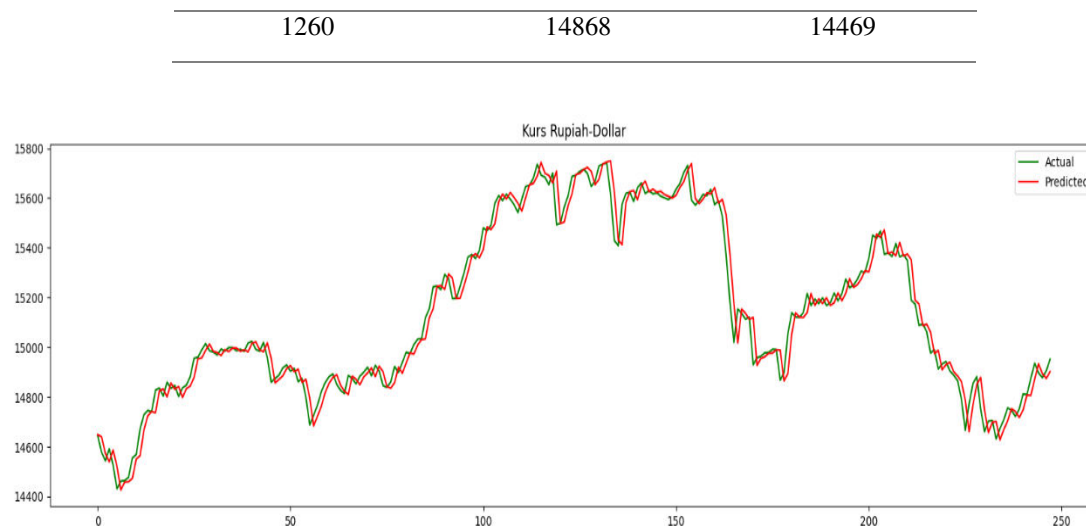
y_pred=best_model.predict(x_test)
y_tests = scaler.inverse_transform(y_test)
print(y_tests)

```

Hasil prediksi pada 10 periode atau 10 hari selanjutnya terdapat pada Tabel 2.4 dengan visualisasi seluruh data aktual dan prediksi terdapat pada Gambar 2.4. Pada plot visualisasi data sumbu x merupakan nilai data ke- dan y merupakan nilai kurs aktual dan prediksi. Dari visualisasi ini, dapat dilihat seberapa dekat atau jauhnya nilai prediksi dari nilai aktual. Jika kedua garis mendekati satu sama lain dan bergerak bersamaan, itu menunjukkan bahwa model peramalan cukup akurat dalam memprediksi nilai aktual. Namun, jika ada variasi atau perbedaan yang signifikan antara kedua garis, itu menandakan bahwa model prediksi mungkin perlu ditingkatkan agar lebih mendekati nilai aktual. Kesimpulan yang terlihat dari Gambar 2.4 adalah hasil prediksi menunjukkan bahwa model yang digunakan cukup akurat karena kedua garis mendekati satu sama lain dan bergerak bersamaan.

**Tabel 2.4.** Hasil Peramalan 10 Periode

Nilai ke-	Nilai Aktual	Nilai Prediksi
1251	14973	14604
1252	14969	14597
1253	15003	14539
1254	14888	14510
1255	14839	14551
1256	14875	14496
1257	14903	14445
1258	14853	14451
1259	14874	14453



**Gambar 2.4.** Visualisasi Data Aktual dan Prediksi

Setelah melakukan proses prediksi, selanjutnya adalah mengukur kinerja model dengan metrik evaluasi. Dalam hal ini, penulis menggunakan metrik evaluasi MSE dan RMSE. Metrik tersebut digunakan untuk melihat seberapa baik model prediksi berfungsi dalam mengestimasi nilai target aktual dari data uji berdasarkan fitur atau variabel independen. Semakin rendah nilai MSE atau RMSE, semakin baik model dalam melakukan prediksi yang lebih akurat. Hasil menunjukkan bahwa data uji memiliki MSE dan RMSE yang lebih rendah dibandingkan dengan data latih. Dalam konteks evaluasi model, memiliki MSE dan RMSE yang lebih rendah menunjukkan bahwa model memiliki kinerja yang lebih baik pada data uji. Model tersebut lebih akurat dalam mengestimasi nilai target pada data uji daripada pada data latih.

**Tabel 2.5.** Perbandingan MSE dan RMSE Data Latih dan Uji

Data	MSE	RMSE
Data Uji ( <i>Testing</i> )	<b>0,000331</b>	<b>0,0182</b>
Data Latih ( <i>Training</i> )	0,000444	0,0210

Selanjutnya, menggunakan model ARIMA. Langkah pertama yang dilakukan adalah melakukan uji stasioneritas Untuk melihat apakah nilai rata-rata, variansi, dan kovariansi antara observasi dari data time series tidak bergantung pada waktu. Dalam hal ini, penulis menggunakan uji ADF dan P-value untuk melihat data Kurs Rupiah-Dolar pada 5 April 2018 hingga 26 Mei 2023 stasioner atau tidak stasioner. Pada Tabel 2.6, merupakan sintaks dari uji stasioneritas 53 menggunakan library stattools adffuller.

**Tabel 2.6.** Sintaks adffuller


```

adf_result = adfuller(df)
print("ADF Statistic: %f" % adf_result[0])
print("p-value: %f" % adf_result[1])
if adf_result[1] > 0.05:
    print("Data Tidak Stasioner")
else:
    print("Data Stasioner")

```

Penulis menggunakan Pustaka auto arima untuk menentukan ordo ARIMA terbaik. Dalam auto\_arima, algoritma secara otomatis mengeksplorasi berbagai kombinasi tersebut dan memilih model ARIMA yang memiliki kriteria terbaik, seperti AIC (Akaike Information Criterion) atau BIC (Bayesian Information Criterion) yang paling rendah. Hal ini mempermudah dan mempercepat proses pemodelan ARIMA. Sehingga, proses prediksi dapat dilakukan secara optimal dan efisien. Hasil dari auto\_arima akan dimasukkan pada lampiran 7. Dari hasil ditunjukkan bahwa ordo terbaik dengan AIC terendah sebesar -6211,034 dan time 4,19 second adalah *ARIMA* (2,1,2).

Hasil prediksi menggunakan pemodelan ARIMA dapat dilihat pada Gambar 2.5. Pada plot visualisasi data sumbu  $x$  merupakan nilai data  $ke$  – dan  $y$  merupakan nilai kurs aktual dan prediksi. Dari visualisasi ini, dapat dilihat seberapa dekat atau jauhnya nilai prediksi dari nilai aktual. Jika kedua garis 54 mendekati satu sama lain dan bergerak bersamaan, itu menunjukkan bahwa model peramalan cukup akurat dalam memprediksi nilai aktual. Namun, jika ada variasi atau perbedaan yang signifikan antara kedua garis, itu menandakan bahwa model prediksi mungkin perlu ditingkatkan agar lebih mendekati nilai aktual. Dari visualisasi tersebut nilai prediksi proses pelatihan cenderung mengikuti pergerakan data aktual. Namun, pada saat proses pengujian tidak mengikuti nilai aktual. Artinya, pemodelan ARIMA kurang tepat digunakan pada prediksi Kurs Rupiah-Dolar Periode 5 April 2018 hingga 26 Mei 2023. Pada proses prediksi pada periode kedepan, garis ungu juga menunjukkan hal yang sama seperti pada proses pengujian. Garis ungu terlihat menunjukkan garis cenderung lurus pada sumbu  $y$ .



**Gambar 2.5.** Grafik Prediksi ARIMA

Setelah melakukan proses prediksi pada tahap pelatihan, selanjutnya adalah mengukur kinerja model dengan metriks evaluasi. Dalam hal ini, penulis menggunakan metriks evaluasi AIC, MSE, dan RMSE. Semakin rendah nilai MSE atau RMSE, semakin baik model dalam melakukan prediksi yang lebih akurat. Perbandingan metriks evaluasi terdapat pada Tabel 2.7.

**Tabel 2.7.** Metriks evaluasi model ARIMA

Metriks evaluasi	Hasil
AIC	-6211,034
MSE	0,0005
RMSE	0,0206

**Tabel 2.8.** Perbandingan Prediksi 10 Periode

Periode	Nilai Aktual	Nilai Prediksi LSTM	Nilai Prediksi ARIMA
1251	Rp14.973,00	Rp15.084,69	Rp14.951,58
1252	Rp14.969,00	Rp15.083,69	Rp14.953,98
1253	Rp15.003,00	Rp15.075,49	Rp14.954,42
1254	Rp14.888,00	Rp15.071,42	Rp14.953,46
1255	Rp14.839,00	Rp15.077,18	Rp14.953,34
1256	Rp14.875,00	Rp15.069,30	Rp14.953,72
1257	Rp14.903,00	Rp15.058,42	Rp14.953,74
1258	Rp14.853,00	Rp15.061,91	Rp14.953,60
1259	Rp14.874,00	Rp15.062,14	Rp14.953,60



1260	Rp14.868,00	Rp15.063,62	Rp14.953,66
------	-------------	-------------	-------------

**Tabel 2.9.** Perbandingan MSE dan RMSE Model LSTM dan ARIMA

Data	Model	MSE	RMSE
Data Latih ( <i>Training</i> )	LSTM	<b>0,0004</b>	<b>0,0210</b>
	ARIMA	0,0005	0,0224
Data Uji ( <i>Testing</i> )	LSTM	<b>0,0003</b>	<b>0,0182</b>
	ARIMA	0,0332	0,1823

#### 4. Simpulan

Hasil evaluasi pemodelan ARIMA menunjukkan bahwa MSE dan RMSE data uji lebih tinggi daripada data latih terlihat pada Tabel 2.9. Dari hasil visualisasi data pada Gambar 2.5, garis prediksi tidak mengikuti garis aktual, artinya pemodelan ini kurang cocok digunakan pada variabel yang dianalisis. Kesimpulannya pemodelan LSTM memiliki akurasi yang lebih baik daripada pemodelan ARIMA yang ditunjukkan pada Tabel 2.9. Dalam melakukan prediksi atau peramalan terdapat faktor lain yang tidak terlihat diluar variabel pada proses analisis data yang dapat mempengaruhi. Pada kasus peramalan nilai tukar Rupiah-Dolar, terdapat variabel lain seperti kebijakan pemerintah, situasi ekonomi negara, kebijakan moneter, dan lain sebagainya. Pengaruh faktor tersebut harus dipertimbangkan dengan cermat karena dapat membantu dalam meningkatkan ketepatan prediksi.

Saran yang dapat diberikan oleh penulis dari analisis dan pembahasan data yang dilakukan adalah dengan mempertimbangkan metode yang digunakan untuk melakukan proses prediksi. Metode ARIMA optimal digunakan untuk memprediksi data dalam jangka waktu yang pendek. Jika metode LSTM optimal digunakan dalam jangka waktu yang panjang dan pendek. Kemudian, mempertimbangkan untuk mengembangkan model *Long-Short Term Memory* lebih lanjut dengan menggabungkan pendekatan berbasis ensemble. Terakhir, pertimbangkan metode pengembangan dari LSTM yaitu bi-LSTM yang dapat membantu mengatasi masalah vanishing gradien problem dengan stabil dan dapat meningkatkan akurasi dalam proses prediksi.

#### Daftar Pustaka

- Abedin, M. Z., Moon, M. H., Hassan, M. K., & Hajek, P. (2021). Deep learning-based exchange rate prediction during the COVID-19 pandemic. *Annals of Operations Research*.  
<https://doi.org/10.1007/s10479-021-04420-6>
- Johan, S. (2020). Peran bank sentral pada masa pandemi covid-19 dan masa yang akan datang (undang undang perbankan no.23 tahun 1999). *Inovasi*, 16(2), 355–361.  
<https://journal.feb.unmul.ac.id/index.php/INOVASI/article/view/7430>
- Nagpure, A. R. (2019). Prediction of multi-currency exchange rates using deep learning. *International Journal of Innovative Technology and Exploring Engineering*, 8(6).
- Oxaichiko Arissinta, I., Dwi Sulistiyawati, I., & Kurnianto Iqbal Kharisudin, D. (2022). Pemodelan Time Series untuk Peramalan Web Traffic Menggunakan Algoritma Arima. *Prosiding Seminar Nasional Matematika*, 5, 693–700.  
<https://journal.unnes.ac.id/sju/index.php/prisma/>

- 
- Pamungkas, P. A., Indrawati, L. R., & Jalunggono, G. (2020). Analisis Pengaruh Ekspor, Impor, Inflasi, Kurs Rupiah, dan Utang Luar Negeri terhadap Cadangan Devisa Indonesia Tahun 1999 – 2018. *DINAMIC: Directory Journal of Economic*, 2(3).
- Rachman, R. (2018). Penerapan Metode Moving Average Dan Exponential Smoothing Pada Peramalan Produksi Industri Garment. *Jurnal Informatika*, 5(2).  
<https://doi.org/10.31311/ji.v5i2.3309>
- Rismala, R., & Elwisam, E. (2020). PENGARUH INFLASI, BI RATE, KURS RUPIAH, DAN HARGA EMAS DUNIA TERHADAP INDEKS HARGA SAHAM SEKTOR PERTAMBANGAN DI INDONESIA. *Oikonomia: Jurnal Manajemen*, 15(2).  
<https://doi.org/10.47313/oikonomia.v15i2.753>
- Rob J Hyndman, & George, A. (2014). Forecasting: Principles and Practice. *Principles of Optimal Design*, September.
- Sanjaya, F. I., & Heksaputra, D. (2020). Prediksi Rerata Harga Beras Tingkat Grosir Indonesia dengan Long Short Term Memory. *JATISI (Jurnal Teknik Informatika Dan Sistem Informasi)*, 7(2). <https://doi.org/10.35957/jatisi.v7i2.388>
- Suebsombut, P., Sekhari, A., Sureephong, P., Belhi, A., & Bouras, A. (2021). Field data forecasting using lstm and bi-lstm approaches. *Applied Sciences (Switzerland)*, 11(24).  
<https://doi.org/10.3390/app112411820>
-